



PROJET – IMA201

SEGMENTATION DE LESIONS CUTANEEES

**REALISE PAR :
SIWAR MHADHBI
EYA GHAMGUI**

ANNEE UNIVERSITAIRE : 2020 - 2021

TABLE DES FIGURES

Figure 1.3.1 – Exemple de transformations des espaces couleurs (RGB, HSI, XYZ).....	3
Figure 2.1 – Pill-box Point Spread Function.....	4
Figure 2.2 – Exemple Image Originale.....	4
Figure 2.3 – Résultat du filtrage du bruit.....	4
Figure 3.1 – Histogramme avant ajustement d'intensité.....	5
Figure 3.2 – Histogramme après ajustement d'intensité.....	5
Figure 3.3 – Image avant ajustement d'intensité.....	5
Figure 3.4 – Image après ajustement d'intensité.....	5
Figure 4.1 – Exemple1 : Image avant seuillage.....	6
Figure 4.2 – Exemple1 : Image après seuillage.....	6
Figure 4.3 – Exemple2 : Image avant seuillage.....	7
Figure 4.4 – Exemple2 : Image après seuillage.....	7
Figure 5.1.1 – Masque adopté (8 - connexité).....	8
Figure 5.2.1 – Gauche : Pas de chevauchement. Droite : Cas de chevauchement.....	9
Figure 5.3.1 – Exemple Image originale.....	9
Figure 5.3.2 – Résultat premier passage.....	10
Figure 5.3.3 – Résultat second Passage.....	10
Figure 5.4.1 – Image après seuillage.....	11
Figure 5.4.2 – Image après conservation des deux plus grandes régions.....	11
Figure 6.1 – Exemple1 : Image avant remplissage morphologique.....	11
Figure 6.2 – Exemple1 : Image après remplissage morphologique.....	11
Figure 6.3 – Exemple2 : Image avant remplissage morphologique.....	12
Figure 6.4 – Exemple2 : Image après remplissage morphologique.....	12
Figure 8.1 – Résultats outils de performance pour chaque image.....	15
Figure 8.2 – Comparaison des canaux de couleur.....	16

TABLE DES MATIERES

Introduction.....	3
1. Transformation des espaces couleurs	4
1.1. Le canal RGB	4
1.2. Le canal HSI	4
1.3. Le canal XYZ.....	5
2. Filtrage du bruit.....	6
3. Ajustement d'intensité	7
4. Seuillage d'histogramme basé sur le clustering	8
5. Étiquetage des composantes connectées.....	9
5.1. Premier passage	10
5.2. Second passage de la première méthode	11
5.3. Second passage de la deuxième méthode.....	12
6. Remplissage : Opérateur Morphologique.....	13
7. Outils de performance utilisés.....	16
7.1. Définitions.....	16
7.1.1 Coefficient de Dice.....	16
7.1.2 Distance de Hausdorff	16
7.1.3 L'indice de Jaccard	16
7.1.4 L'indice Rand Ajusté	17
7.1.5 La métrique Variation de l'information.....	17
7.1.6 Les informations mutuelles normalisées	17
8. Evaluation.....	18
Conclusion.....	22
Références	23

Introduction

Depuis plus de cinquante ans, la fréquence de cancers cutanés augmente, surtout celle du mélanome. Une analyse des images dermoscopiques permettrait d'aider les médecins dans leurs diagnostic et dépistage des lésions de la peau. Celles qui peuvent être malignes dans le cas de cancers ou bénignes dans le cas de grains de beauté.

La première étape vers l'analyse automatisée des mélanomes malins est la segmentation automatique des lésions cutanées. Celle-ci est l'objet de notre projet. Ce présent rapport présente les différentes étapes amenant à la segmentation des lésions cutanées décrites par l'article "*Skin Lesion Segmentation Using Color Channel Optimization and Clustering-based Histogram Thresholding*" [1].

Ces étapes se divisent en deux parties, la pré-segmentation et la segmentation des lésions. Les étapes de pré-segmentation sont des prétraitements d'images ; les images résultantes lissées sont plus appropriées pour une analyse et un diagnostic précis. C'est pourquoi, ces étapes jouent un rôle très important dans le domaine de l'imagerie médicale.

Nous avons implémenté l'algorithme de segmentation automatique de cet article qui est principalement basé sur l'analyse de l'espace colorimétrique et sur le seuillage de l'histogramme par grappes, un processus qui permet de déterminer un bon canal de couleur pour la détection des bords dans les images dermoscopiques.

En premier lieu, nous allons transformer nos images en différents espaces couleurs. Ensuite, nous décrivons la phase du filtrage du bruit et celle d'ajustement d'intensité qui participent au lissage de l'image. Dans un second temps, nous décrivons le principe de seuillage d'histogramme basé sur le clustering et sur la méthode d'Otsu. Après, viennent les algorithmes d'étiquetage des composantes connectées afin de distinguer entre les différents objets de l'image. Enfin, on procède par remplissage des trous présents dans le résultat final à l'aide d'un opérateur morphologique en 8-connexité.

Finalement, l'algorithme est testé sur un ensemble de 20 images de dermoscopie haute résolution. Une évaluation des résultats est fournie, où les frontières déterminées manuellement par des dermatologues, sont comparées à des frontières détectées par l'algorithme proposé, en appliquant six outils de performance. Utilisant ces résultats, on peut comparer ces différents outils ainsi que déterminer le canal de couleur optimal parmi ceux étudiés pour la détection des bords dans les images de dermoscopie.

1. Transformation des espaces couleurs

Le traitement des images couleur est devenu un domaine d'étude et d'application important. La représentation d'une image dans plusieurs espaces colorimétriques révélera plusieurs caractéristiques de l'image qui ne sont pas visibles dans d'autres coordonnées. À ce propos, nous appliquerons les méthodes implémentées sur les différents canaux (RGB, HSI et XYZ).

1.1. Le canal RGB

C'est le canal initial de l'image. R correspond à la composante rouge, G correspond à la composante verte et B correspond à la composante bleue. Cette décomposition nous permet d'analyser les 3 composantes des couleurs primaires de chaque partie de l'image.

1.2. Le canal HSI

Le modèle de couleur HSI représente chaque couleur avec trois composantes : teinte (H), saturation (S) et intensité (I). Le composant Hue décrit la couleur comme un angle compris entre $[0, 360]$ degrés. Le composant Saturation décrit le degré de dilution de la couleur avec la lumière blanche. La plage de S est comprise entre $[0, 1]$. La plage d'intensité est comprise entre $[0, 1]$ et 0 signifie noir, 1 signifie blanc. La composante de teinte est proportionnelle à la longueur d'onde moyenne de la couleur, la saturation indique la quantité de blanc dans la couleur et l'intensité représente la luminosité ou la quantité d'énergie dans la couleur. Les formules des composantes HSI s'écrivent comme suit :

$$I = \frac{R + G + B}{3}$$

$$S = 1 - \frac{3}{R + G + B} [\min(R, G, B)]$$

$$W = \cos^{-1} \left(\frac{R - \frac{1}{2}(G + B)}{\sqrt{[(R - G)^2 + (R - B)(G - B)]}} \right)$$

$$H = \begin{cases} W & \text{if } G > B \\ 2\pi - W & \text{if } G < B \end{cases}$$

1.3. Le canal XYZ

C'est une description quantitative des couleurs conforme à la vision humaine. La composante Y est utilisée pour décrire l'intensité lumineuse subjective indépendante de la couleur. De plus, X et Z sont choisies pour décrire les couleurs visibles.

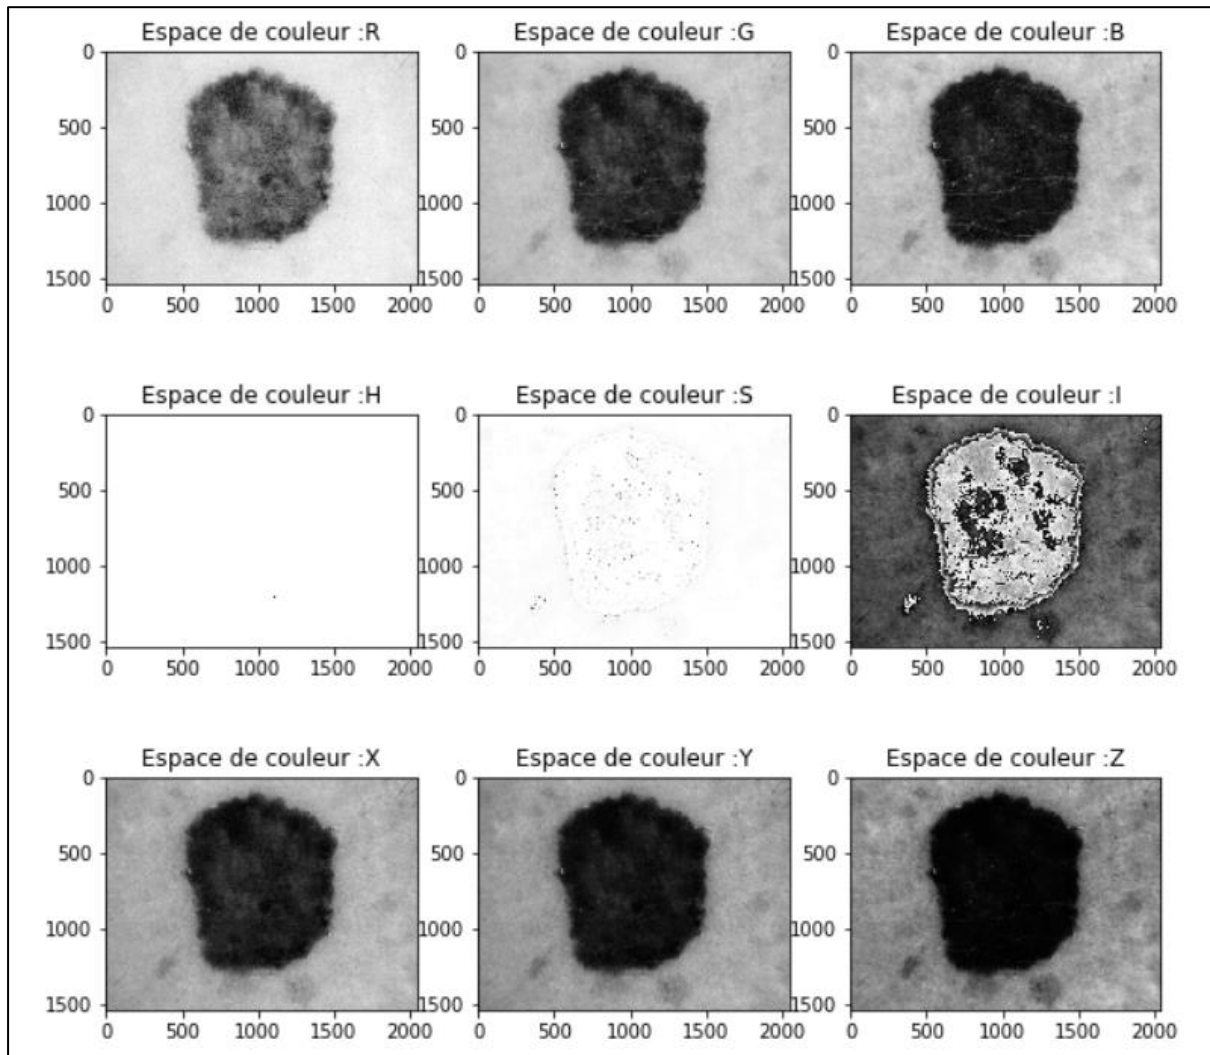


Figure 1.3.1 – Exemple de transformations des espaces couleurs (RGB, HSI, XYZ).

On remarque que la région de lésion est bien représentée et visible dans les canaux 'G', 'B', 'I', 'X', 'Y' et 'Z'. Pour les canaux 'H' et 'S', on remarque que la région de la lésion n'est pas visible et ce résultat va être constaté sur les indices de performances de la segmentation dans les prochaines parties.

2. Filtrage du bruit

Dans les images de dermoscopie, des artefacts externes comme les lignes de peau, les bulles d'air ou autres bruits aléatoires causés par le processus d'imagerie peuvent exister.

Le filtrage linéaire peut améliorer et lisser les images de dermoscopie de nombreuses façons : en réduisant le bruit aléatoire, en corrigeant les inégalités d'éclairage ou le flou, etc. La procédure de filtrage linéaire est réalisée en convoluant l'image originale avec un noyau de filtre approprié. On applique dans notre étude comme filtre linéaire un filtre passe-bas à moyennage circulaire avec rayon égal à 5, en utilisant la fonction **Pill-box point spread function**.

Cette méthode nous permet ainsi d'augmenter la précision du résultat de la segmentation et de gagner du temps de calcul.




Figure 2.1 - Pill-box Point Spread Function.




Figure 2.2 – Exemple Image Originale.




Figure 2.3 – Résultat du filtrage de bruit.

3. Ajustement d'intensité

Dans cette étape, on vise à lisser et étirer l'histogramme et à augmenter le contraste de l'image afin de trouver une valeur seuil plus précise dans l'étape suivante qui consiste à seuiller l'histogramme basant sur le clustering.

Cette étape est essentiellement un processus d'amélioration dans lequel la gamme dynamique des valeurs des pixels de l'image est représentée dans une nouvelle gamme pour laquelle l'histogramme est un peu plus étalé.

Pour ce faire, on commence par représenter l'échelle des valeurs d'intensité dans l'image originale de façon à couvrir toute la gamme dynamique de $[0,1]$. Cette mise à l'échelle linéaire est faite de sorte que 1% des données soient saturées au plus bas (0) et au plus haut (1) des intensités.

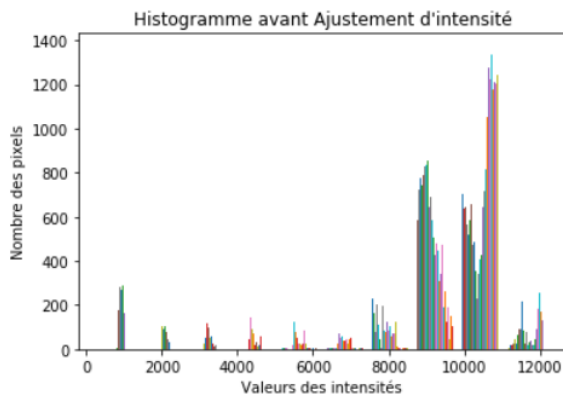


Figure 3.1 – Histogramme avant ajustement d'intensité.




Figure 3.2 – Histogramme après ajustement d'intensité.




Figure 3.3 – Image avant ajustement d'intensité.




Figure 3.4 – Image après ajustement d'intensité.

4. Seuillage d'histogramme basé sur le clustering

Afin de bien localiser la lésion dans la peau, on essaie de segmenter l'image en deux régions : la première est notre région d'intérêt qui est la lésion ou le grain de beauté (le premier plan), et la deuxième correspond à l'environnement (le fond). Ceci est l'objet de cette quatrième partie.

La méthode qu'on envisage dans ce projet est la méthode de seuillage qui, à partir d'une image en niveau de gris, crée une image comportant uniquement deux valeurs 0 (noir) ou 1 (blanc).

Et pour identifier correctement les deux régions envisagées on cherchera un seuil optimal. A cette fin, on se base sur la méthode d'Otsu qui définit le seuil optimal séparant les deux régions en minimisant la variance intra-groupe. Cette dernière est définie comme suit :

$$\sigma_w^2(t) = \omega_1(t)\sigma_1^2(t) + \omega_2(t)\sigma_2^2(t)$$

Où les poids w_i sont les probabilités des deux clusters séparés par un seuil t et σ_i sont les variances de ces clusters.

Il a été démontré que la réduction de la variance intra-classe est équivalente à la maximisation de la variance entre les groupes définis par :

$$\sigma_b^2(t) = \sigma^2 - \sigma_w^2(t) = \omega_1(t)\omega_2(t)[\mu_1(t) - \mu_2(t)]^2$$

Où μ_i sont les valeurs moyennes des deux clusters.

L'image de sortie est alors binaire ayant des valeurs égales à 1 pour tous les pixels de l'image d'entrée dont la luminance est supérieure au niveau seuil et 0 pour les pixels restants.




Figure 4.1 – Exemple1 : Image avant seuillage.

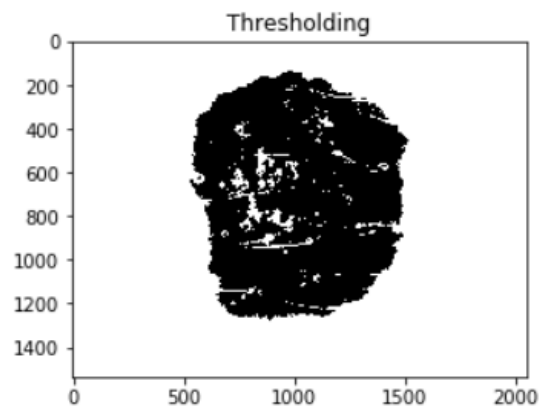


Figure 4.2 – Exemple1 : Image après seuillage.

Par addition à la segmentation, cette méthode nous permet d'enlever du bruit résiduel comme par exemple les poils de faible intensité. Ceci est illustré par l'exemple de la figure 4.3.

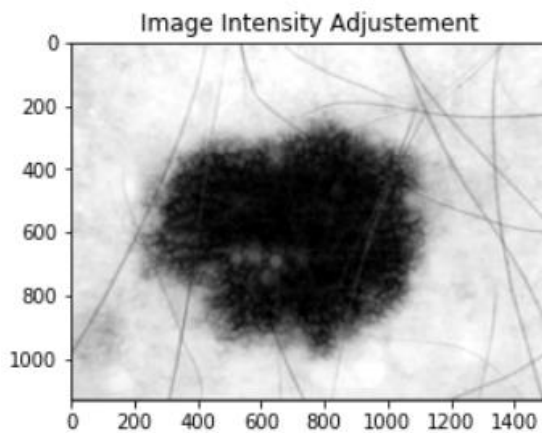


Figure 4.3 – Exemple2 : Image avant Seuillage.

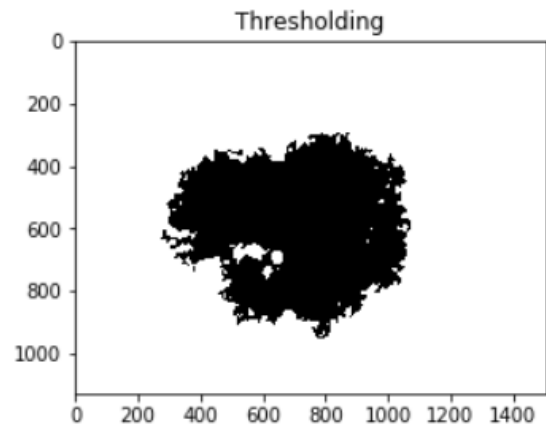


Figure 4.4 – Exemple2 : Image après Seuillage.

5.Étiquetage des composantes connectées

Sur certaines images de la peau, des objets supplémentaires peuvent apparaître dans la zone cutanée environnante, comme par exemple les marques bleues faites par les dermatologues lors de l'examen de la peau du patient.

Ces objets, qui n'ont pas été éliminés ni lors de l'étape d'élimination du bruit ni lors de l'étape du seuillage, apparaissent avec des valeurs d'intensité similaires à celles de la lésion et peuvent être mal classés en tant que lésions.

L'objectif de cette étape est donc d'exclure ces objets de la sortie de la segmentation.

Pour ce faire, on a envisagé deux méthodes :

- La première est extraite de l'article considéré, celui dont nous avons implémenté l'algorithme. Elle est basée sur la technique de Run Length Encoding tout en étiquetant les objets connectés.
- La seconde est basée sur l'association des étiquettes par groupes.

Toutes ces deux méthodes sont caractérisées par deux passages et partagent le même premier passage. Elles seront décrites dans les paragraphes qui suivent.

5.1. Premier passage

Dans le premier passage, on parcourt tous les pixels de l'image et pour chacun on regarde le demi-masque (en 8-connexité) associé, celui représenté en contour noir dans la figure suivante :




Figure 5.1.1 – Masque adopté (8 - connexité) [3].

Si des pixels du masque sont déjà étiquetés (de valeur $\neq 0$), on ajoute l'étiquette minimale au pixel en question (pixel rouge dans la figure précédente)

Pour les pixels de bord, un traitement particulier est appliqué, comme généralement les lésions se trouvent centrés dans l'image, pas aux bords, on a ajouté un contour de pixels noirs à l'image avant d'appliquer l'algorithme. A la fin, ce contour est supprimé.

Ces étiquettes accordées sont enregistrées sous forme de matrice dont les pixels correspondent à ceux de l'image originale.




Figure 5.3.1 – Exemple Image originale [4].




Figure 5.3.2 – Résultat premier passage [4].

5.2. Second passage de la première méthode

Dans ce passage, on parcourt la matrice des étiquettes ligne par ligne et on cherche les séquences de pixels consécutifs ayant la valeur 0 (les pixels noirs consécutifs). Sur chaque séquence trouvée, on associe à chaque pixel de la séquence le couple (début, fin) où :

- Début : l'ordre du premier pixel noir de la séquence.
- Fin : l'ordre du dernier pixel noir de la séquence.

Ensuite, on parcourt le résultat obtenu pixel par pixel à partir de la seconde ligne et on compare chaque pixel du pixel au-dessus. Dans le cas de chevauchement, c'est à dire dans le cas où :

- Le début du pixel en question est entre le début et la fin de celui au-dessus.
- Le début du pixel en question est inférieur au début du pixel au-dessus et sa fin est supérieure à celle du pixel au-dessus.

On associe les deux séquences en les affectant la même étiquette qui est la valeur minimale des deux étiquettes.

On représente deux situations dans la figure 5.2.1, où à gauche on n'a pas de chevauchement, et à droite c'est un cas de chevauchement.




Figure 5.2.1 – Gauche : Pas de chevauchement.
Droite : Cas de chevauchement [3].

5.3. Second passage de la deuxième méthode

Pour la deuxième méthode, lors du parcours du premier passage et au moment d'ajout d'étiquette au pixel en question, on sauvegarde tous les étiquettes trouvées dans le masque dans une liste.

Après, lors du second passage, on remplace tous les étiquettes par le minimum de la liste qui leur correspond.




Figure 5.3.3 – Résultat second Passage [4].

A la fin de ces deux méthodes, les deux régions obtenues sont celles de plus grandes zones et toutes les autres composantes sont éliminées.

La figure 5.3.5 montre le résultat de cette étape sur l'image dermoscopique de la figure 5.3.4.




Figure 5.3.4 Image après seuillage.




Figure 5.3.5 Image après conservation des deux plus grandes régions.

5.4 Comparaison entre les deux méthodes

En termes de temps de calcul, la première méthode a pris 0.41126 secondes pour une image choisie. Par contre, la deuxième méthode a pris 6.90002 secondes pour la même image.

En termes de mémoire, le pourcentage de mémoire utilisée par la première méthode est égal à 0.1 % et le pourcentage de mémoire utilisée par la deuxième méthode est égale à 0.2 %.

On note que la première méthode présente un temps de calcul 14 fois moins et un pourcentage de mémoire utilisée 2 fois moins que ceux de la deuxième méthode. Cette différence va causer un problème lors de l'application de cette méthode sur une série d'images de tailles plus grandes. Pour cela, on va choisir la première méthode qui est basée sur la méthode du Run Length Encoding.

6. Remplissage : Opérateur Morphologique

Nos résultats de segmentation comprennent des trous à l'intérieur des objets de lésion. Afin d'éliminer ces trous, on utilise l'opération de remplissage morphologique sur l'image binaire.

Cette opération consiste à envahir la complémentarité des formes en entrée à partir du bord extérieur de l'image, à l'aide de dilatations binaires. Les trous ne sont pas connectés à la limite et ne sont donc pas envahis. Le résultat est le sous-ensemble complémentaire de la région envahie.

Le résultat de cette méthode est illustré par les figures suivantes :




Figure 6.1 Exemple1 : Image avant remplissage morphologique.

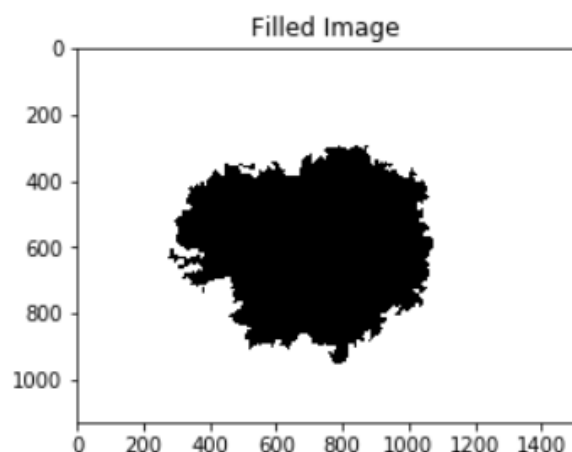


Figure 6.2 Exemple1 : Image après remplissage morphologique.




Figure 6.3 Exemple2 : Image avant remplissage morphologique.




Figure 6.4 Exemple2 : Image après remplissage morphologique.

7. Comparaison visuelle entre trois résultats

7.1. Exemple mauvais résultat




Figure 7.1.1 Exemple mauvais résultat.

La figure 7.1.1 nous montre le résultat de cette méthode sur une image contenant des poils intenses. La méthode d'Otsu a détecté plusieurs détails indésirables, elle a considéré les poils et la lésion comme un unique objet. De la sorte, le fond apparaît comme des trous dans l'image qui ont été bouchés par l'opérateur morphologique résultant en une image toute noire.

Ainsi, les images avec des poils sont les limites de cette méthode. Afin d'éliminer ces défauts, on peut avoir recours à des méthodes d'enlèvement de poils comme celle du DullRazor.

7.2 Exemple résultat moyen




Figure 7.2.1 Exemple résultat moyen.

La figure 7.2.1 nous montre un résultat moyen de notre algorithme de segmentation. On remarque bien que la lésion est détectée et que les trous sont bouchés. Cependant, des parties de la lésion ne sont pas détectées à cause de leurs intensités relativement faibles.

Ainsi, on peut dire que notre algorithme est limité par certaines valeurs d'intensités de l'image de la lésion mal traitées au niveau du seuillage par la méthode d'Otsu.

7.3 Exemple bon résultat




Figure 7.3.1 Exemple bon résultat.

La figure 7.3.1 correspond à une détection parfaite de la lésion cutanée. La qualité originale de l'image a joué un rôle important dans cette détection : l'image initiale présente seulement la lésion sans autres objets.

8. Outils de performance utilisés

8.1 Définitions

8.1.1 Coefficient de Dice

Le coefficient de Dice est une mesure de similarité entre deux images données. Les valeurs de ce coefficient varient entre 0 et 1. Il se définit comme la fraction de la double intersection entre l'image segmentée et la vérité terrain et l'union de ces deux images. La formule ci-dessous résume la méthode de calcul :

$$DSC = \frac{2|A \cap B|}{|A| + |B|}$$

Avec : A l'image segmentée et B la vérité terrain.

8.1.2 Distance de Hausdorff

C'est la distance maximale entre deux ensembles A et B. Elle mesure la dissimilarité entre deux images binaires (l'image segmentée et la vérité terrain). Elle est définie comme suit :

$$H(A, B) = \max(h(A, B), h(B, A))$$

Avec :

- $h(A, B) = \max_{a \in A} \min_{b \in B} ||a - b||$
- $||\cdot||$ est la norme euclidienne.

8.1.3 L'indice de Jaccard

L'indice de Jaccard, également connu sous le nom de coefficient de similitude de Jaccard, est une statistique utilisée pour comprendre les similitudes entre des ensembles d'échantillons. Il est formellement défini comme le cardinal de l'intersection entre ces deux échantillons divisés par la cardinalité de leurs unions.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

Avec : A l'image segmentée et B la vérité terrain.

8.1.4 L'indice Rand Ajusté

L'indice Rand est défini comme la somme du nombre de vrais résultats positifs et le nombre de vrais résultats négatifs divisé par le nombre total des éléments. Cet indice varie entre 0 et 1. Lorsque deux partitions s'accordent parfaitement, l'indice Rand atteint la valeur maximale 1. Un problème avec cet indice est que la valeur attendue entre deux partitions aléatoires n'est pas une constante. Ce problème est corrigé par l'indice Rand ajusté. Un indice Rand ajusté plus grand signifie un accord plus élevé entre deux partitions. Il est exprimé par cette formule :

$$RI = \frac{TP + TN}{TP + FP + FN + TN}$$

Avec :

- TP : vraies valeurs positives
- TN : vraies valeurs négatives
- FN : fausses valeurs négatives
- FP : fausses valeurs positives

8.1.5 La métrique Variation de l'information

La métrique Variation de l'information est définie comme la distance entre deux images. Cette distance est exprimée comme l'entropie conditionnelle moyenne d'une segmentation connaissant l'image de la vérité terrain. De plus, cette métrique mesure approximativement la quantité d'aléa dans une segmentation.

$$VI(A, B) = H(A) + H(B) - 2I(A, B)$$

Avec :

- $H(A)$ l'entropie de A
- $I(A, B)$ l'information mutuelle
- A l'image segmentée et B la vérité terrain.

8.1.6 Les informations mutuelles normalisées

Les informations mutuelles normalisées sont les informations entre les zones de chevauchement de deux images. Cette métrique mesure la dépendance entre deux images. La représentation mathématique de cet indice s'écrit par l'équation :

$$NMI(A, B) = \frac{H(A) + H(B)}{H(A, B)} = 1 + \frac{I(A, B)}{H(A, B)}.$$

Avec :

- $H(A)$ l'entropie de A
- $H(A, B)$ l'entropie conjointe
- $I(A, B)$ l'information mutuelle
- A l'image segmentée et B la vérité terrain.

9. Evaluation

Afin d'évaluer cet algorithme, nous utilisons les différents outils de performance décrits dans la partie précédente. Ces outils sont appliqués sur les différentes images de notre base de données qui renferme 20 images de dermoscopie avec leurs masques correspondants.

Les résultats sont sauvegardés dans un "dataframe" présenté par la figure 8.1. Ce "dataframe" représente les différents résultats obtenus des outils de performance pour chaque canal (R, G, B, H, S, I, X, Y, Z) d'une image de notre base de données.

		Dice	Hausdorff Distance	Jaccard Index	Adjusted Rand Index	Volumetric Similarity	Normalized Mutual Information
Name	Canal						
ISIC_0000030.jpg	R	0.663890	20.199010	0.496882	0.000000e+00	0.663890	2.562813e-15
	G	0.310941	22.538855	0.184091	2.666755e-03	0.555677	3.151400e-03
	B	0.302600	23.579652	0.178273	1.687318e-03	0.554243	1.923977e-03
	H	0.000000	1.414214	0.000000	-2.921258e-08	0.000005	2.336127e-06
	S	0.000000	1.414214	0.000000	-2.921258e-08	0.000005	2.336127e-06
	I	0.268088	28.670542	0.154793	4.426981e-02	0.798183	3.902931e-02
	X	0.434390	22.649503	0.277457	1.935168e-02	0.694131	1.893355e-02
	Y	0.456498	22.516660	0.295754	2.643076e-02	0.710022	2.536063e-02
	Z	0.427825	22.583180	0.272123	1.790700e-02	0.687044	1.770744e-02
ISIC_0000046.jpg	R	0.546956	20.688161	0.376421	0.000000e+00	0.546956	-5.364329e-15
	G	0.546956	20.688161	0.376421	0.000000e+00	0.546956	-5.364329e-15
	B	0.546956	20.688161	0.376421	0.000000e+00	0.546956	-5.364329e-15
	H	0.000000	1.414214	0.000000	-9.336837e-07	0.000006	1.679817e-06
	S	0.000000	1.414214	0.000000	-9.336837e-07	0.000006	1.679817e-06
	I	0.032369	30.364453	0.016451	6.289916e-01	0.812469	5.488580e-01
	X	0.681793	18.330303	0.517213	3.804193e-01	0.715340	3.447784e-01
	Y	0.684871	17.175564	0.520763	3.850103e-01	0.715464	3.512318e-01
	Z	0.738381	22.715633	0.585264	4.568850e-01	0.757005	4.197592e-01

Figure 8.1 – Exemples résultats outils de performance pour chaque image.

Afin de comparer entre les outils de performance, nous avons calculé les moyennes de ces indices pour toutes les 20 images pour chaque canal, ainsi que leurs écart-types. Les résultats sont représentés par les plots ci-dessous.

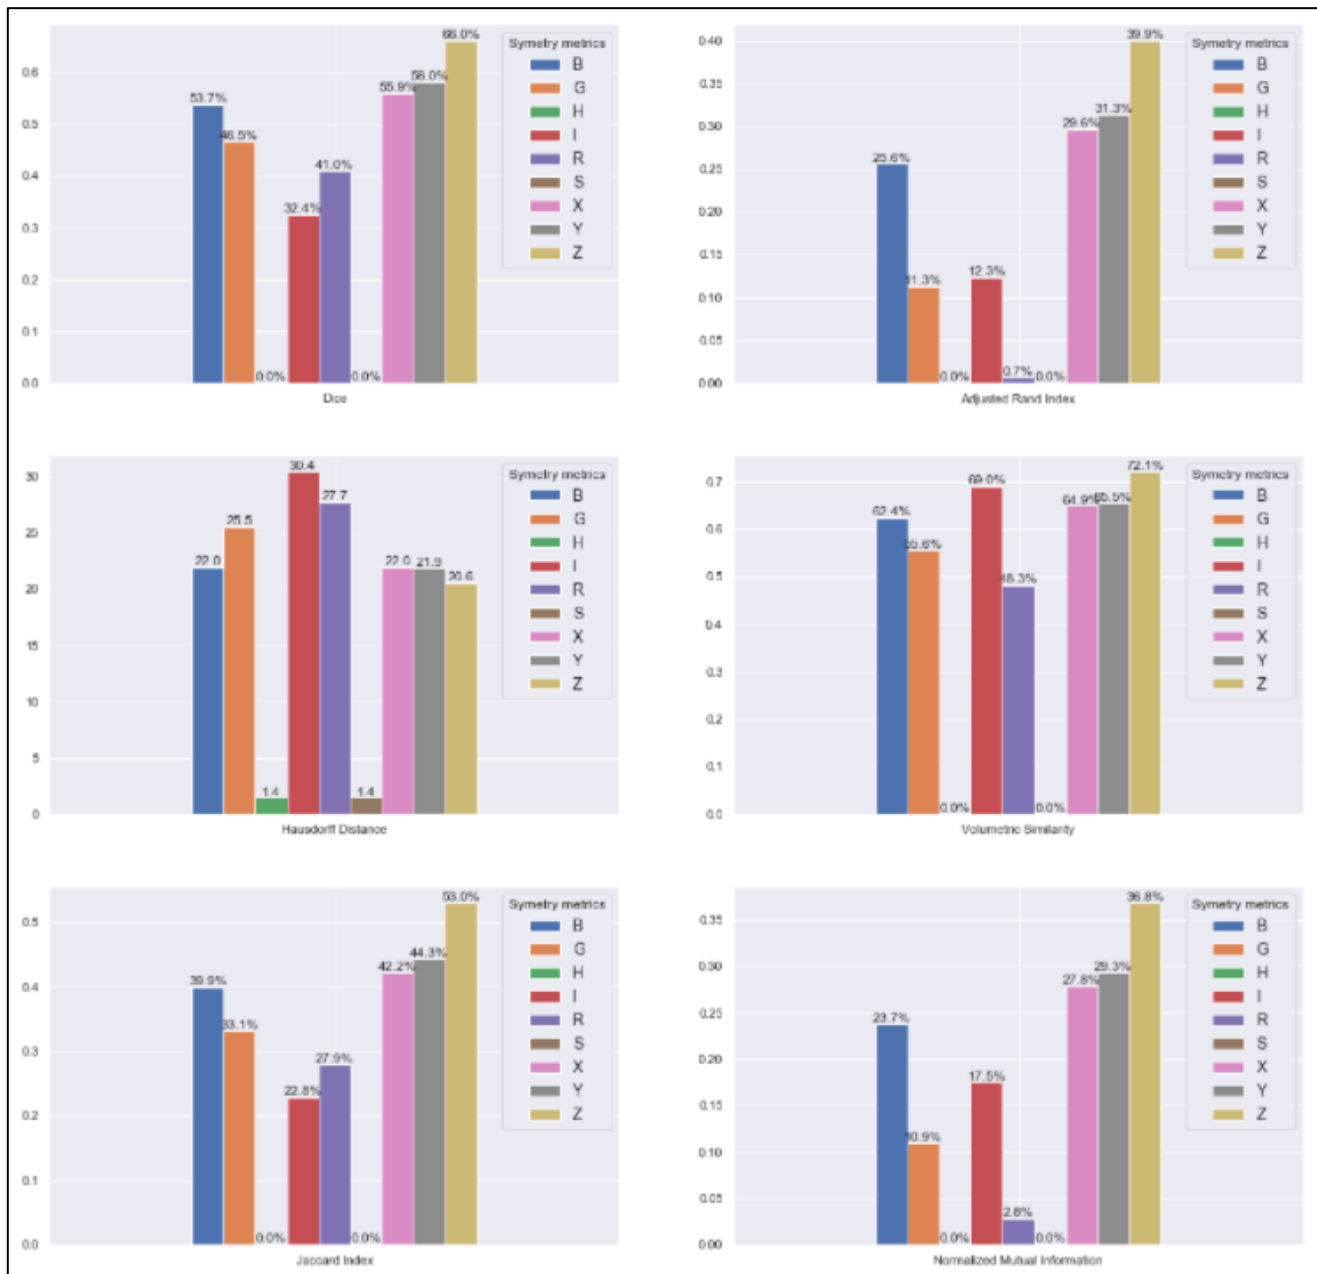


Figure 8.2 – Comparaison entre les moyennes des indices de performances moyennés sur les 20 images de la base de données des canaux de couleur.




Figure 8.3 – Comparaison entre les écarts types des indices de performances sur les 20 images de la base de données des canaux de couleur.

Commentaires :

- À partir des figures précédentes, on remarque que l'espace colorimétrique XYZ a fourni les meilleurs résultats de segmentation sur presque toutes les images de notre base de données. De plus, on constate que le canal Z est le plus performant parmi les canaux de cet espace avec un Dice moyen égal à 0,66.

- Concernant les canaux de l'espace colorimétrique RGB, on remarque qu'ils sont moins performants que les canaux de l'espace XYZ mais plus performants que ceux de l'espace colorimétrique HSI. De plus, on peut noter que le canal bleu est le plus performant parmi ces trois canaux RGB et le canal rouge est celui avec les mauvais indices de performance.

- Les canaux de l'espace HSI sont les moins performants pour presque tous les indices comparés avec les autres canaux.

- A partir des résultats des écart-types des indices de performance (cf. figure 8.3), on remarque que ces variations sont proches pour tous les canaux à l'exception des canaux H et S de l'espace HSI. De plus, le canal I représente une plus grande variation ; ce qui signifie que les variations des erreurs de segmentation sont plus grandes dans ce canal.

=> On peut alors conclure que l'espace HSI n'est pas adapté à notre application de segmentation. Cependant, l'espace XYZ est le meilleur pour cette segmentation, plus précisément le canal Z.

Conclusion

En guise de conclusion, notre projet vient comme une étape primordiale dans l'étude des images dermoscopiques qui consiste à extraire, à partir de l'image, la région formant la zone d'intérêt. La caractérisation de la qualité de cette approche sur l'image médicale est de plus en plus un défi persistant.

Au sein de ce projet, nous avons arrivé à implémenter les différentes parties de l'article [1] qui ont pour objectif de segmenter les images dermoscopiques de lésions cutanées. Les premières phases qui consistent à transformer l'espace de couleur, filtrer l'image et ajuster l'intensité nous ont aidé à améliorer les résultats par l'élimination du bruit et le lissage de l'image. Par ailleurs, ces phases nous ont permis de trouver une valeur seuil plus précise lors de l'étape suivante du seuillage de l'histogramme basé sur le clustering et par suite mieux différencier les objets de l'image par l'algorithme d'étiquetage des composantes connectées.

Par l'analyse des résultats et à travers la comparaison faite sur les différents espaces couleurs en se basant sur les indices de performance, on a trouvé que le meilleur espace couleur dans cette étude est l'espace XYZ. Plus précisément, le canal Z a montré des résultats meilleurs de segmentation des lésions cutanées.

On peut aller encore plus loin dans notre projet en implémentant un algorithme du "Hair Removal" afin d'éliminer les poils dans les images dermoscopiques qui sont souvent des objets gênants dans les méthodes de segmentation puisque, dans le cas de forte intensité, ils peuvent être considérés comme objet unique avec la lésion.

Références

- [1] <https://perso.telecom-paristech.fr/ladjal/projetsIMA201/2019/Garnavietal.pdf>
- [2] https://scikit-image.org/docs/dev/auto_examples/color_exposure/plot_equalize.html
- [3] https://www.researchgate.net/publication/228912595_FPGA_implementation_of_a_single_pass_real-time_blob_analysis_using_run_length_encoding
- [4] https://en.wikipedia.org/wiki/Connected-component_labeling
- [5] https://www.analog.com/media/en/technical-documentation/dsp-book/dsp_book_Ch24.pdf
- [6] <https://deepai.org/machine-learning-glossary-and-terms/jaccard-index?fbclid=IwAR3s5l4RhX5neSjHEdfOrMbBWl5GPsJM6OGLQCoMz9doY-6-HIJMQsYvgel>
- [7] https://en.wikipedia.org/wiki/S%C3%B8rensen%E2%80%93Dice_coefficient?fbclid=IwAR3EDuEdagpztNgmYxkwBjSgQt_waAk9yuSPOEc9n5PbfVfp5nLmJwz87zA
- [8] https://en.wikipedia.org/wiki/Rand_index